타이타닉 생존 예측 프로젝트

- 데이터 분석 및 머신러닝 기반 생존 요인 분석

김혜민 | 2026.04

목차

- 프로젝트 개요
- 데이터 소개
- 문제 정의
- Info
- 결측값 처리
- EDA (단변량 분석)
- EDA (이변량 분석)
- 통계 검정
- Feature Engineering
- 모델링
- Feature Importance
- 결과
- 한계
- 결론

프로젝트 개요

Titanic Survival Prediction

타이타닉 데이터를 기반으로 생존 여부를 예측하고,
단순 모델링이 아닌 데이터 기반 분석을 중심으로 진행했습니다.

- EDA 기반 변수 분포 및 생존 패턴 분석
- 통계 검정을 통한 변수 유의성 검증
- 파생 변수 생성 (Feature Engineering)
- 모델 비교 및 성능 평가

데이터 기반으로 변수의 영향을 분석하고 예측 모델을 구축

데이터 소개

- 데이터셋: Kaggle Titanic Dataset
- Train 891건 / Test 418건

- 주요 변수:
  - 성별(Sex), 나이(Age)
  - 요금(Fare), 객실 등급(Pclass)

승객 특성에 따라 생존 여부가 달라지는 구조

- 범주형 변수와 수치형 변수가 혼합된 데이터
- 문제 유형: 이진 분류 (Binary Classification)

문제 정의

타이타닉 승객 데이터를 기반으로 생존 여부를 예측하고,

생존에 영향을 미치는 주요 요인을 분석하는 것을 목표로 합니다.

- 승객 정보로 생존 여부를 예측할 수 있는가?
- 어떤 변수들이 생존에 유의미한 영향을 미치는가?

info

[basic_info_summary]

	train_dtype	train_nunique	train_missing_count	train_missing_ratio
PassengerId	int64	891	0	0.00
Survived	int64	2	0	0.00
Pclass	int64	3	0	0.00
Name	object	891	0	0.00
Sex	object	2	0	0.00
Age	float64	89	177	19.87
SibSp	int64	7	0	0.00
Parch	int64	7	0	0.00
Ticket	object	681	0	0.00
Fare	float64	248	0	0.00
Cabin	object	148	687	77.10
Embarked	object	4	2	0.22

- Age 약 20% 결측 → 보완 필요
- Cabin 약 77% 결측 → 직접 사용 어려움
- Embarked 결측 거의 없음 → 단순 대체 가능

결측값 처리

[train 결측 현황]

	missing_count	missing_ratio
Cabin	687	77.10
Age	177	19.87
Embarked	2	0.22

- Age
  - Pclass + Sex 기준 중앙값 대체
  → 그룹별 특성 반영

- Embarked
  - 최빈값 대체
  → 결측 비율이 낮아 단순 대체 적용

- Fare
  - 중앙값 대체
  → 이상치 영향 최소화

- Cabin
  - 결측 비율 높아 파생 변수 활용

→ 데이터 손실 최소화 및 정보 보존

EDA (단변량 분석)

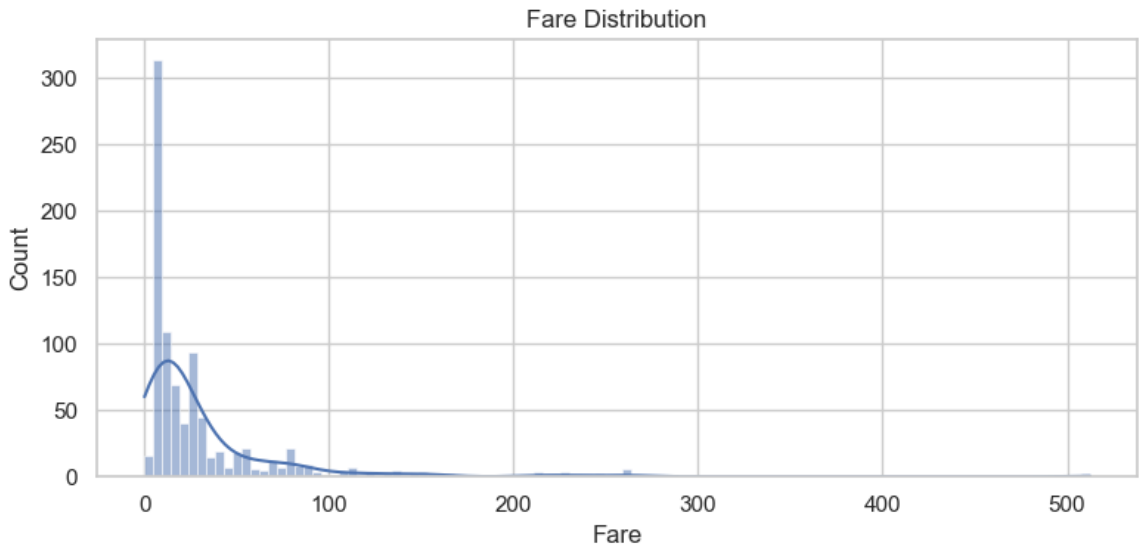

- Fare는 이상치 영향이 크며, 오른쪽으로 강하게 치우친 분포를 보임

  → 로그 변환을 통해 모델 학습에 유리하도록 개선

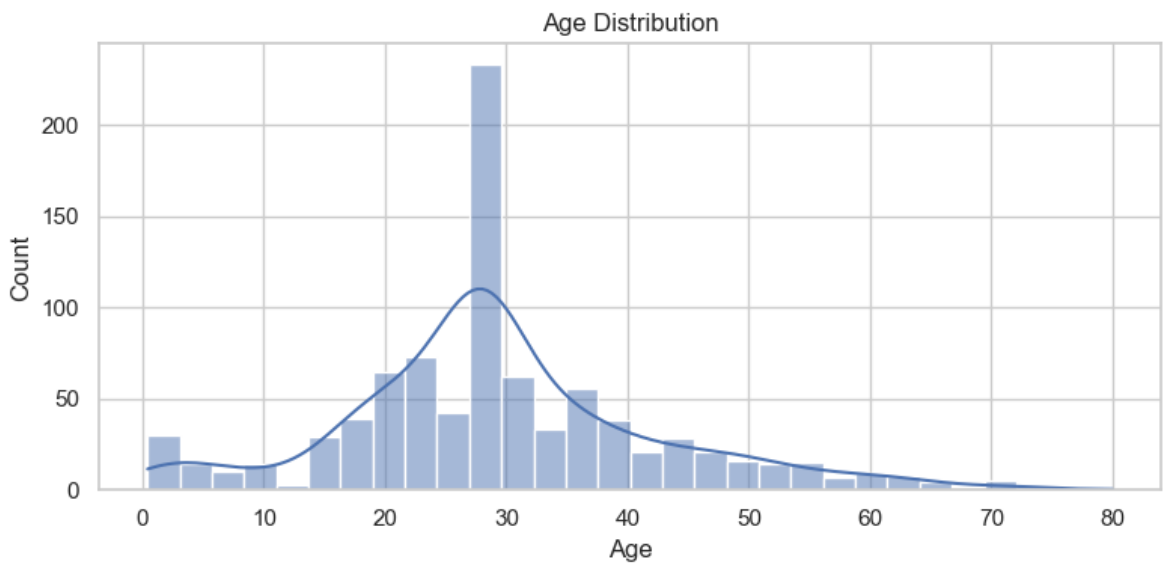

- Age는 비교적 정규분포에 가까운 형태를 보임

EDA (이변량 분석)

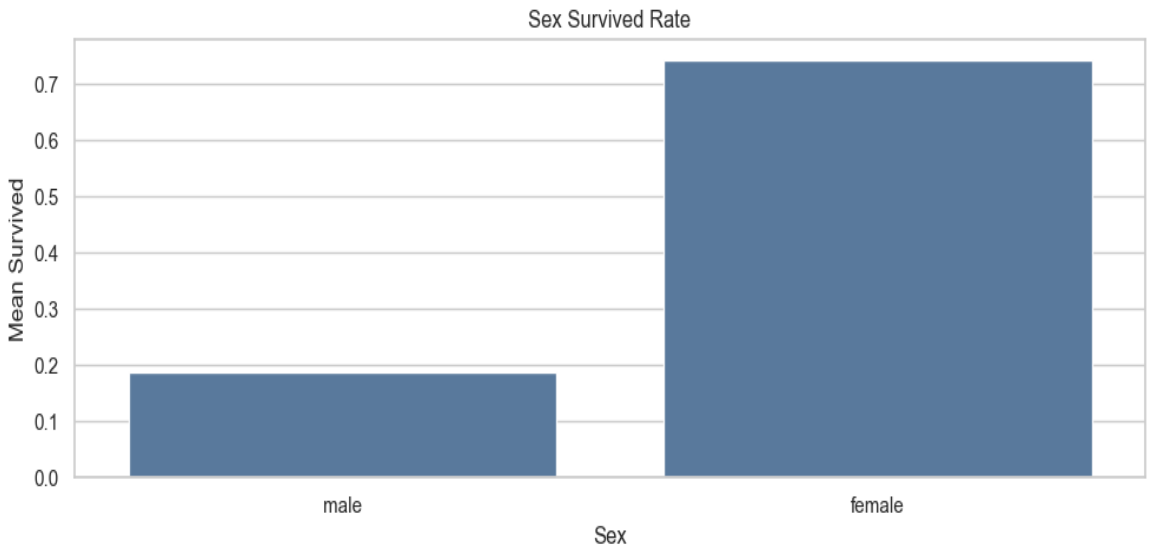

- 성별(Sex)

  - 여성 생존률 > 남성

  → 주요 변수로 판단

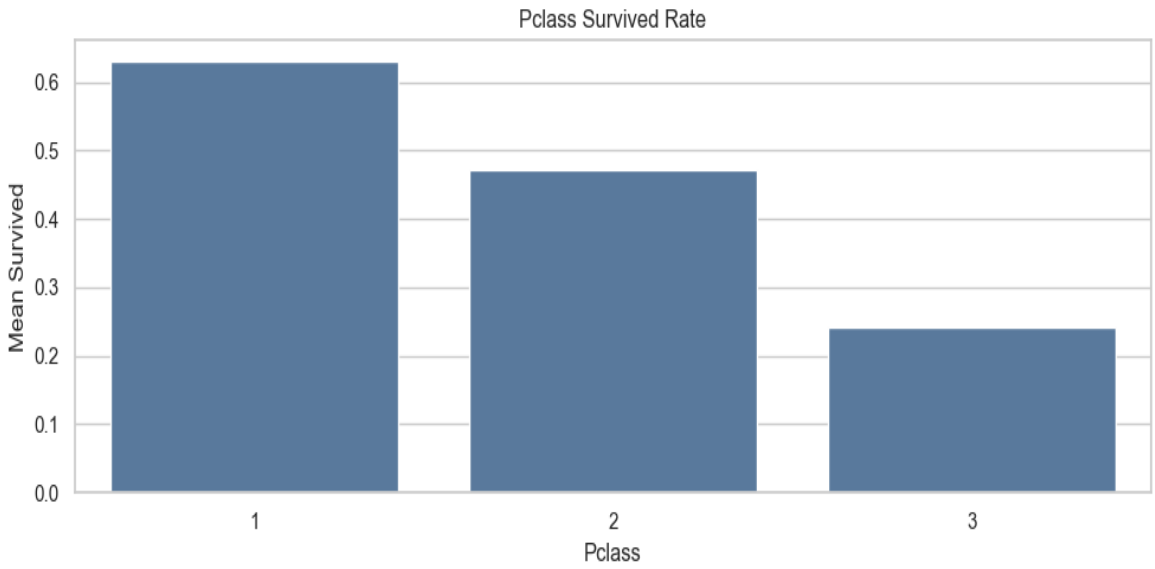

- 객실 등급(Pclass)

  - 상위 등급일수록 생존률 ↑

  → 주요 변수로 판단

통계 검정

variable	test	chi2_stat	p_value
Sex	chi_square	260.7170	0.0000
Pclass	chi_square	102.8890	0.0000

variable	test	t_stat	p_value
Fare	welch_t_test	6.8391	0.0000
Age	welch_t_test	-1.6921	0.0911

- 성별(Sex) → 생존 여부에 유의미한 영향 ($p < 0.05$)
- 객실 등급(Pclass) → 생존 여부에 유의미한 영향 ($p < 0.05$)
- Fare → 생존 여부에 따라 평균 차이가 유의미하게 나타남 ($p < 0.05$)
- Age → 유의미한 차이 없음 ($p > 0.05$)

→ 주요 변수의 통계적 유의성 확인

→ EDA 결과의 신뢰성 확보

→ 주요 변수 중심으로 모델링 진행

Feature Engineering

Title	FamilySize	IsAlone	AgeBand	Fare_log	FareBand	CabinDeck	TicketPrefix
Mr	2	0	YoungAdult	2.110213	Low	M	A
Mrs	2	0	YoungAdult	4.280593	High	C	PC
Miss	1	1	YoungAdult	2.188856	MidLow	M	STONO

```
[rare 적용 - train]
 Title
Mr        517
Miss      185
Mrs       126
Master     40
Rare       23
```

- Title

→ Name에서 호칭 추출 → 사회적 지위 반영

→ Rare 그룹화로 모델 안정성 확보

- FamilySize, IsAlone

→ 가족 단위 여부 반영

→ IsAlone 기준 생존율 차이

- 가족 있음: 약 51%
- 혼자: 약 30%

→ 주요 변수로 판단

- AgeBand, FareBand

→ 연속형 변수 구간화 → 패턴 단순화

- Fare_log

→ 로그 변환 → 왜도 감소 및 분포 안정화

- CabinDeck

→ 객실 위치 정보 활용 → 구조 접근성 반영

- TicketPrefix

→ 티켓 유형 기반 그룹 정보 반영

→ 모델 성능 개선 및 변수 해석력 향상

모델링

- 사용 모델

→ Logistic Regression / Decision Tree

→ Random Forest / Gradient Boosting

- 모델 선택 기준

→ 교차 검증 기반 성능 비교 (Stratified K-Fold)

→ F1 Score 기준 평가 (불균형 데이터 고려)

- 최종 모델

→ Random Forest (최종 선택)

- 선택 이유

→ 비선형 관계 및 변수 간 상호작용 학습

→ Ensemble 기반으로 과적합에 강함

- 결과

→ 가장 높은 F1 Score 기록 → 최종 모델 선정

Feature Importance

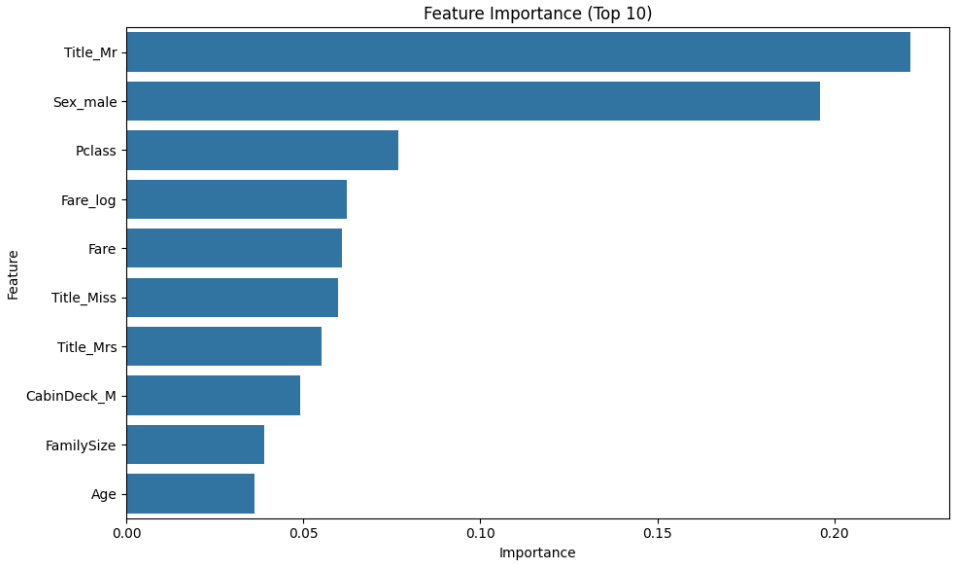

- 주요 변수 중요도 분석 (Random Forest)

→ 주요 변수: Sex, Pclass, Fare_log, Title, FamilySize

- 해석

→ Sex : 여성의 생존률이 높았던 EDA 결과와 일치
→ Pclass : 상위 등급일수록 생존률이 높은 패턴 반영
→ Fare_log : 요금이 높을수록 생존 확률 증가 (계층 반영)
→ Title : 성별 및 사회적 지위, 보호 대상 여부 반영
→ FamilySize : 가족 규모에 따른 생존 전략 차이 반영

→ Title과 같은 파생 변수가 높은 중요도를 보이며,
Feature Engineering의 효과 확인

→ EDA에서 발견한 패턴이 모델에서도 주요 변수로 반영됨

결과

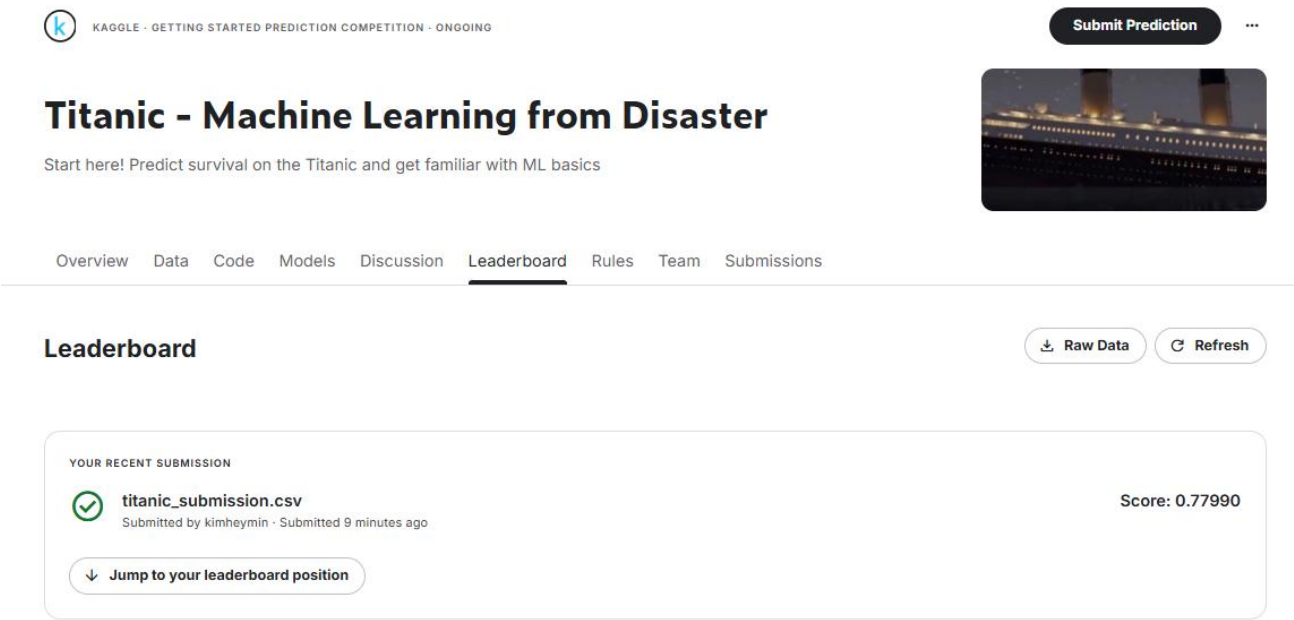

→ Random Forest 모델이 교차 검증 기준 가장 높은 성능을 기록

→ 교차 검증 F1 Score(0.7715)와 Kaggle 점수(0.77990)가
유사하게 나타나 일반화 성능이 안정적으로 확보됨

→ EDA 및 Feature Engineering 과정에서 도출한 변수들이
실제 모델 성능 향상에 기여

→ 특히 성별, 객실 등급, 요금, 호칭 등
생존과 관련된 변수들이 모델에 효과적으로 반영됨

한계

- 주요 한계

→ 하이퍼파라미터 튜닝 미흡으로 성능 개선 여지 존재

→ Feature Engineering 과정에서 변수 간 중복 정보 가능성 존재
(예: FamilySize와 IsAlone)

→ Tree 기반 중요도에 의존하여 변수 해석이 제한적

→ 외부 데이터 미활용으로 다양한 요인 반영에 한계

결론

→ Titanic 데이터 분석을 통해 생존에 영향을 주는 변수 확인

→ 성별, 객실 등급, 요금, 호칭 등 생존과 관련된 패턴 도출

→ Feature Engineering을 통해 모델 성능 및 변수 해석력 향상

→ Random Forest 모델이 가장 높은 성능을 보이며
안정적인 일반화 성능을 확인